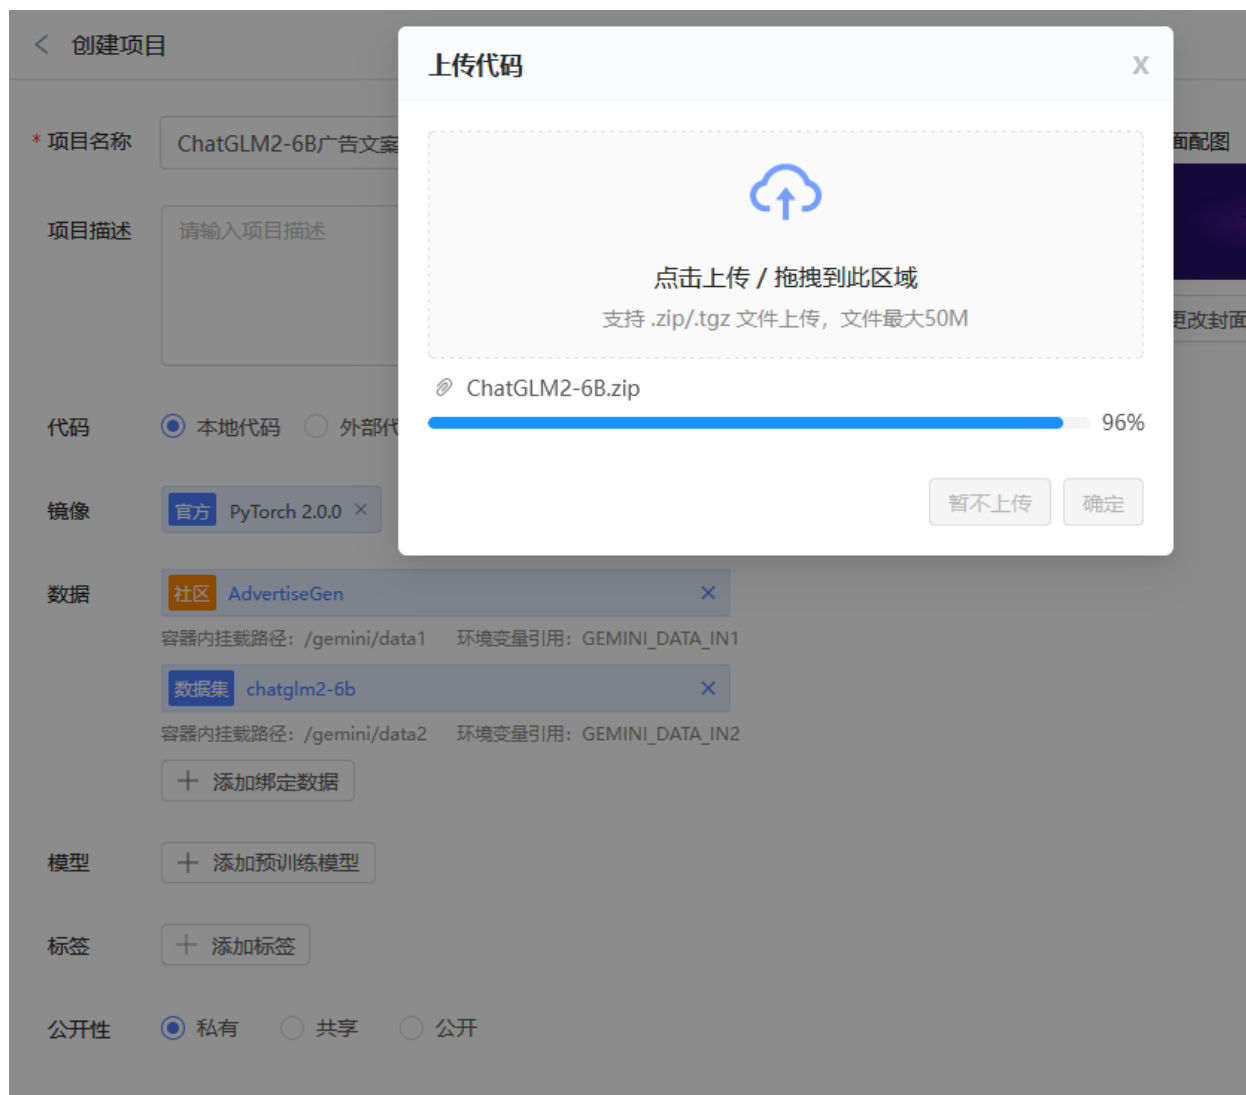


金水Task2笔记

1.首先和Task1流程类似，先配置好环境，数据，和要运行的代码



2.镜像换为chatglm2-6b,并进行端口77的开放

ID: 360747710078259200 [🔗](#)

进入开发环境

开发环境实例

[修改实例规格](#)
[修改挂载数据](#)
[修改镜像](#)
[修改 SSH 配置](#)
[修改最长运行时间](#)

实例	GPU	挂载数据	代码版本	镜像
B1.large	1	2 数据集	latest	ChatGLM2-...

[运行记录](#)
[历史记录](#)
[事件](#)

创建 2023-09-23 21:22

等待中

等待配额 2023-09-23 21:22

任务调度 2023-09-23 21:22

进入任务池 ✓ 2023-09-23 21:22

等待调度 ✓ 2023-09-23 21:22

任务调度 ✓ 2023-09-23 21:22

代码准备 ✓ 2023-09-23 21:22

状态 [停止运行](#)

等待中 [设为紧急](#)

开放端口 [添加](#)

外部访问地址需在开发环境启动, 且程序正常运行后使用。 [查看文档](#)

内部端口: 77 | TCP 协议

外部访问: 需在开发环境启动后分配

使用用途: chatglm2-6b 网页形式访问

开发者工具

[JupyterLab](#)
[网页终端](#)

开始时间

2023-09-23 21:25

自动停止

已设置最大运行时长为8 h

3,改下requirements.txt

```
requirements.txt
1  protobuf
2  transformers==4.30.2
3  cpm_kernels
4  torch>=2.0
5  gradio
6  mdtex2html
7  sentencepiece
8  accelerate
9  sse-starlette
10 streamlit>=1.24.0
11 rouge_chinese
12 nltk
13 jieba
14 datasets
```

4.在终端运行

```
pip install -r ChatGLM2-6B/requirements.txt -i https://pypi.virtacloud.com/repository/pypi/sim
```

安装成功

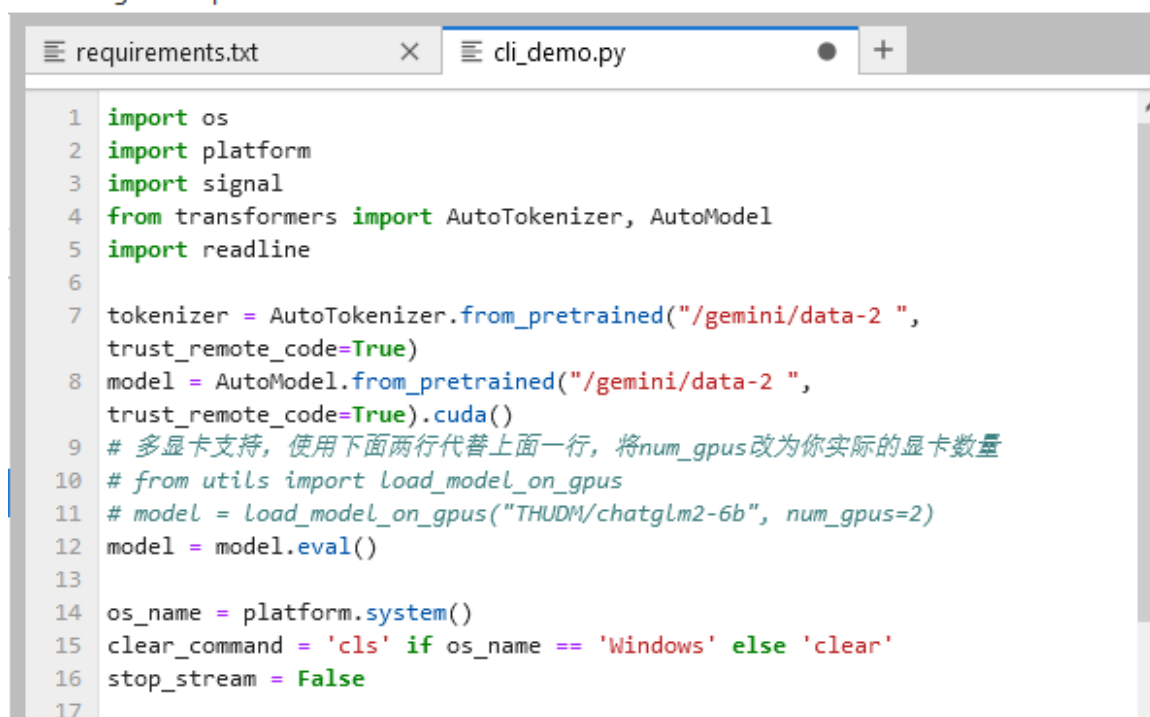
```

t (line 5)) (0.19.3)
Collecting mdurl~=0.1 (from markdown-it-py>=2.2.0->rich<14,>=10.14.0->streamlit>=1.24.0->-r ChatGLM2-6B/requirements.txt (line 10))
  Downloading https://pypi.virtacloud.com/repository/pypi/packages/mdurl/0.1.2/mdurl-0.1.2-py3-none-any.whl (10.0 kB)
Installing collected packages: watchdog, validators, tzlocal, toml, tenacity, smmap, safetensors, mdurl, blinker, pydeck, markdown-it-py, gitdb, transformers, sse-starlette, rich, gitpython, streamlit
  Attempting uninstall: transformers
    Found existing installation: transformers 4.27.1
    Uninstalling transformers-4.27.1:
      Successfully uninstalled transformers-4.27.1
Successfully installed blinker-1.6.2 gitdb-4.0.10 gitpython-3.1.37 markdown-it-py-3.0.0 mdurl-0.1.2 pydeck-0.8.1b0 rich-13.5.3 safetensors-0.3.3.post1 smmap-5.0.1 sse-starlette-1.6.5 streamlit-1.27.0 tenacity-8.2.3 toml-0.10.2 transformers-4.30.2 tzlocal-5.0.1 validators-0.22.0 watchdog-3.0.0
WARNING: Running pip as the 'root' user can result in broken permissions and conflicting behaviour with the system package manager. It is recommended to use a virtual environment instead: https://pip.pypa.io/warnings/venv

[notice] A new release of pip is available: 23.1.1 -> 23.2.1
[notice] To update, run: python -m pip install --upgrade pip
root@360748546191790080-taskrole1-0:/gemini/code#

```

5.修改 cli_demo.py 中模型的地址，将 THUDM/chatglm2-6b 替换为 /gemini/data-2 （即模型实际挂载到环境的地址）



```

1 import os
2 import platform
3 import signal
4 from transformers import AutoTokenizer, AutoModel
5 import readline
6
7 tokenizer = AutoTokenizer.from_pretrained("/gemini/data-2 ",
8 trust_remote_code=True)
9 model = AutoModel.from_pretrained("/gemini/data-2 ",
10 trust_remote_code=True).cuda()
11 # 多显卡支持, 使用下面两行代替上面一行, 将num_gpus改为你实际的显卡数量
12 # from utils import load_model_on_gpus
13 # model = load_model_on_gpus("THUDM/chatglm2-6b", num_gpus=2)
14 model = model.eval()
15
16 os_name = platform.system()
17 clear_command = 'cls' if os_name == 'Windows' else 'clear'
18 stop_stream = False
19

```

6.1. 切换至 网页终端。执行如下命令唤醒交互式对话。等待最终 Loading checkpoint shards: 100% 且返回 用户: 字样。。

```
python ChatGLM2-6B/cli_demo.py
```

成功

```
[notice] To update, run: python -m pip install --upgrade pip
root@360754075593084928-taskrole1-0:/gemini/code# python ChatGLM2-6B/cli_demo.py
Loading checkpoint shards: 100%|██████████████████████████████████████████████████████████████████████████████| 7/7 [02:21<00:00, 20.15s/it]
欢迎使用 ChatGLM2-6B 模型，输入内容即可进行对话，clear 清空对话历史，stop 终止程序

用户：你好啊

ChatGLM: 你好 🌸 我是人工智能助手 ChatGLM2-6B，很高兴见到你，欢迎问我任何问题。
```